PILOTO SDD · CUENTAS PERSONALES

Feature 001 — Métricas de tiempo, tokens y costos

Ciclo SDD completo (spec → ship) ejecutado con GLM 5.3 el 2026-11-06. Tokens medidos de las transcripciones reales; costos calculados con tarifas de mercado.

COSTO DIRECTO ≈ $8,50 | ~66 MIN EFECTIVOS | 26,8M TOKENS TOTALES | 1 INTERVENCIÓN HUMANA

Las cifras del ciclo

$8,53
COSTO DIRECTO API

66 min
TRABAJO EFECTIVO

26,79M
TOKENS CONSUMIDOS

1
INTERVENCIÓN HUMANA

Tarifas usadas (GLM 5.3)

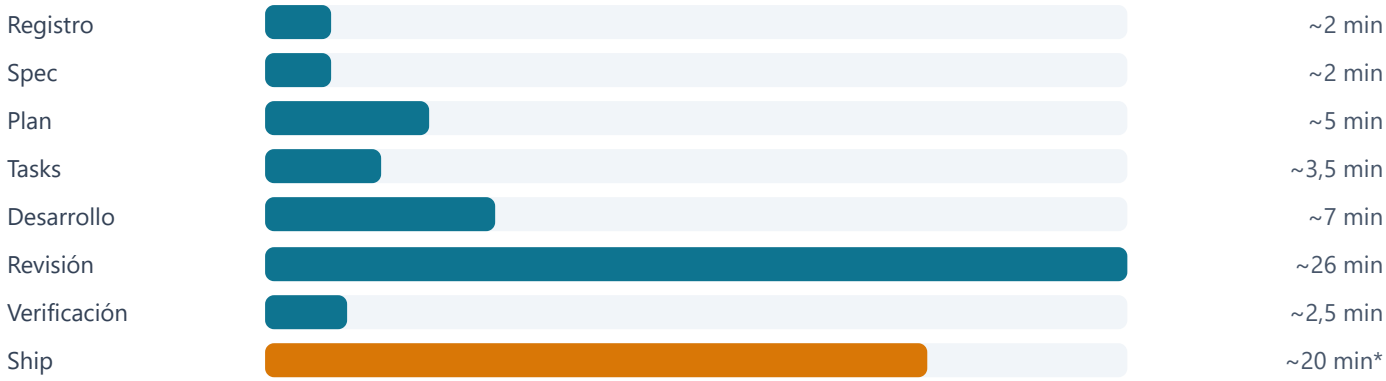
Z.ai no publica tarifas por token en sus páginas públicas de precios — su vía comercial principal es la suscripción *GLM Coding Plan*. Las tarifas por token usadas aquí son las que registra **Artificial Analysis** para la API estándar de GLM 5.3:

Concepto	Tarifa (USD por 1M tokens)	Nota
Input (contexto nuevo)	$1,40	Contexto que el modelo lee por primera vez
Output (generación)	$4,40	Texto producido por el modelo
Input cacheado (lectura)	≈ $0,27	Descuento de caché del 81% sobre input

Por qué esto importa aquí: el 98% de los tokens del ciclo fueron *lecturas de caché* (el contexto largo se relee en cada paso, pero cacheado). Esos 26,1M de tokens a $0,27 cuestan **$7,04** — el 85% del costo total. Sin el descuento de caché, esos mismos tokens facturarían como input nuevo y el ciclo costaría **≈ $37,70**. La caché ahorró **$29,47 (78%)**.

Supuestos y honestidad de los datos: (1) las tarifas por token provienen de un agregador que rastrea las tarifas oficiales de la API — si tu proveedor cobra distinto, el costo escala linealmente (los tokens son la parte medida). (2) Los 134.940 tokens de los 4 subagentes de revisión no tienen desglose in/out: se estiman en ~$0,30 (rango $0,12–0,59 según composición). (3) No incluye tu tiempo humano ni la suscripción, si usás el Coding Plan (ver página 4).

Tiempo por paso



* ≈15 min del ship fueron esperas por cortes transitorios del clasificador de permisos del harness (no del proyecto). Trabajo efectivo: ~66 min. Ventana total del ciclo: 21:56 → 23:32 UTC (96 min).

Tokens por paso

Paso	Input	Caché leída	Output	Total paso
Spec	28.413	1.452.480	8.939	1.489.832
Plan	25.813	3.564.480	17.174	3.607.467
Tasks	92.792	1.398.784	6.122	1.497.698
Desarrollo	124.072	3.209.472	19.747	3.353.291
Revisión	126.511	9.393.408	56.007	9.575.926
Verificación	7.576	1.181.312	8.008	1.196.896
Ship	27.001	5.886.528	15.643	5.929.172
Subagentes (4)		134.940 sin desglose in/out		134.940
Total	**432.178**	**26.086.464**	**131.640**	**26.785.222**

Lectura de la tabla

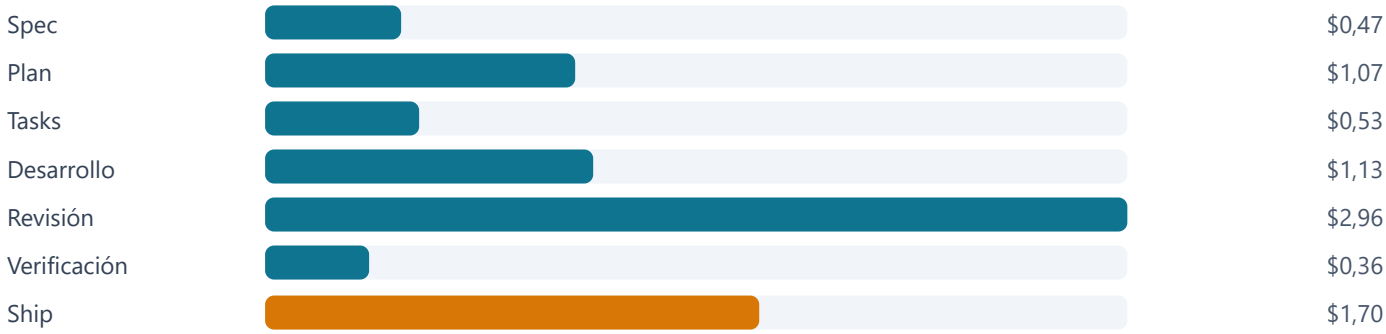
- **La caché es el 98% del volumen:** el contexto del piloto se relee completo en cada paso, pero cacheado — por eso 26M de tokens cuestan solo $7.
- **La revisión es el paso más caro en todo:** más tiempo (26 min), más tokens (9,6M) y más costo ($2,96). Es también el paso que encontró el blocker real.
- **El output es mínimo:** 132k tokens generados (0,5%) — el trabajo del ciclo fue mayormente leer contexto y producir cambios quirúrgicos.

Costo por paso (USD, API pay-as-you-go)

Paso	Input $1,40/M	Caché $0,27/M	Output $4,40/M	Costo paso
Spec	$0,04	$0,39	$0,04	$0,47
Plan	$0,04	$0,96	$0,08	$1,07
Tasks	$0,13	$0,38	$0,03	$0,53
Desarrollo	$0,17	$0,87	$0,09	$1,13
Revisión	$0,18	$2,54	$0,25	$2,96
Verificación	$0,01	$0,32	$0,04	$0,36
Ship	$0,04	$1,59	$0,07	$1,70
Subagentes (est.)		sin desglose — estimado		~$0,30
Total del ciclo	**$0,61**	**$7,04**	**$0,58**	**≈ $8,53**

Cifras por paso redondeadas al centavo; el total suma los valores sin redondear. Rango real considerando la incertidumbre de los subagentes: **$8,35 – $8,82**.

Costo por paso



El efecto caché, en dinero

Escenario	Costo del ciclo
Con descuento de caché (lo que se pagó)	≈ $8,53
Si toda la caché se facturara como input nuevo	≈ $37,70
Ahorro por caché	**$29,47 (78%)**

¿Y con la suscripción (GLM Coding Plan)?

La vía comercial oficial de Z.ai para este caso de uso es el *GLM Coding Plan*, por suscripción. La documentación oficial define el consumo en **créditos**: `(input × 6,9 + cacheada × 1,7 + output × 24) ÷ 10.000` para GLM 5.3.

Plan (docs oficiales)	Créditos / 5 h	Créditos / semana	Precio
Lite	2.000	10.000	desde $18/mes
Pro	12.000	60.000	—
Max	28.000	140.000	—

El ciclo completo de la feature 001 consumió **≈ 5.050 créditos** (sesión principal) + ~100–325 de subagentes ≈ **5.200–5.400 créditos**: la feature entera cabe en **la mitad de una semana del plan Lite**. Z.ai declara un ahorro de hasta 92% frente al pago por uso de la API estándar.

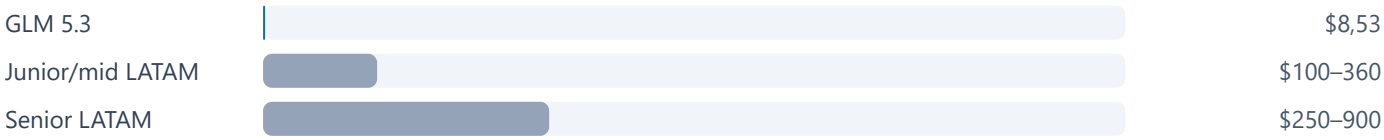
Comparación: ¿y si se hace a mano?

Estimación aproximada del mismo alcance hecho por un desarrollador humano: spec + plan, desarrollo TDD (generador, ruta, UI, 9 tests), dos rondas de revisión, verificación con Excel y ship con documentación.
Supuestos explícitos — ajustá las tarifas a tu realidad:

Actividad	Estimación manual
Spec + plan + desglose de tareas	2–4 h
Desarrollo TDD (código + 9 tests)	4–8 h
Revisión de código (2 rondas + fixes)	2–3 h
Verificación (app viva + Excel)	1–2 h
Ship (PR + documentación)	~1 h
Total	**10–18 h (≈ 2–3 días laborables)**

Costo aproximado por perfil

Escenario	Tarifa/h	Costo (10–18 h)
Dev junior/mid LATAM	$10–20	$100–360
Dev senior LATAM	$25–50	$250–900
Dev senior US/EU	$80–150	$800–2.700
Ciclo con GLM 5.3 (este piloto)	**—**	**≈ $8,53 + tu supervisión**



Senior US/EU $800–2.700

> **Lectura honesta:** en dinero directo, el ciclo AI fue **12–300 veces más barato** según el perfil. Pero la economía real no es el dinero — es el **tiempo**: 66 minutos efectivos contra 2–3 días laborables, con 1 intervención humana. El costo que no desaparece es tu rol: elegir la feature, supervisar el autopilot y confiar en (o repetir) la verificación. El cuello de botella se movió del teclear al gobernar el proceso.

Tokens y tiempos: medidos de las transcripciones del ciclo (`02-DOCS/wiki/sdd/features/001-exportar-csv.md`).
Tarifas por token: Artificial Analysis — artificialanalysis.ai/models/glm-5-3 (GLM 5.3: $1,40/M in · $4,40/M out · descuento caché 81%).
Planes y créditos: documentación oficial Z.ai — docs.z.ai/devpack/overview (Coding Plan Lite/Pro/Max, multiplicadores GLM 5.3).
Comparación manual: estimación con supuestos explícitos, no medición. Generado el 2026-11-06.